

Хемотаксис-память: когда retrieval по направлению перехода выигрывает у похожести, а когда нет

T-Lab 2026 · Lifelong Agents · задание 1

Аннотация

Remember the Decision, Not the Description (Zou et al., 2026) утверждает, что воспоминание ценно не своей похожестью на текущую ситуацию, а тем, насколько его потеря изменила бы будущее решение агента. Мы проверяем операциональное следствие этой идеи для retrieval-памяти: извлечение по вектору направления перехода (по аналогии с бактериальным хемотаксисом: run/tumble вдоль градиента, а не абсолютное положение) против извлечения по точечной семантической похожести. Строим синтетическую среду с управляемой связью между похожестью и полезностью (два режима) и сравниваем четыре метода retrieval при равном бюджете памяти на geometric kNN-агенте (Tier 1, статистически мощная проверка) и на реальном LLM-агенте (Tier 2, Qwen2.5-0.5B-Instruct). Центральная гипотеза не подтверждается: после поправки Холма-Бонферрони на множественные сравнения хемотаксис нигде не превосходит point cosine статистически значимо, а на низком-среднем ρ значимо хуже него и concat cosine почти везде. Результат воспроизводится на реальных диалогах (LoCoMo, 1986 вопросов) без какой-либо конструкции под него. Собственная гипотеза о зависимости оптимального окна направления от негладкости среды также отвергается. Затем мы формулируем и проверяем вторую, производную гипотезу: направление обязано быть полезным сигналом, если верное действие — функция именно *перехода*, а не пары состояний, и представление достаточно линейно относительно этого перехода. В этом специально сконструированном режиме хемотаксис статистически значимо превосходит concat, но только в узком окне умеренной силы сигнала: на реальных эмбедингах текста такой линейной структуры нет, и преимущество не возникает нигде. Обученный PyTorch-комбинатор поверх тех же признаков показывает похожую картину: в основной среде вклад направления мал, но не нулевой, а в специально сконструированной — велик и статистически надёжен. Отрицательный результат в основной постановке и положительный в производной вместе дают связный, проверяемый ответ на вопрос «когда»: не «работает всегда» и не «не работает никогда», а зависит от конкретного, измеримого условия на структуру задачи и представления.

1. Введение

Агент, который долго работает с пользователями или средой, не может держать всю историю в контексте и должен решать, что помнить. Стандартный ответ: хранить и извлекать по семантической похожести (RAG-стиль: эмбединг текущей ситуации против эмбедингов прошлых эпизодов). DeMem предлагает другой критерий: ценность воспоминания определяется не похожестью, а тем, изменила бы его потеря будущее решение.

Биологическая мотивация. Название и механизм отсылают к хемотаксису кишечной палочки (*E. coli*). Бактерия физически слишком мала, чтобы почувствовать разницу концентрации аттрактанта в пространстве вдоль длины собственного тела — градиент для неё неощутим. Вместо этого она сравнивает концентрацию сейчас с концентрацией несколько секунд назад, пока плывёт: сравнение принципиально временное, а не пространственное. Движение чередует два режима — run (прямолинейное плавание) и tumble (случайный кувырок со сменой направления): если концентрация растёт по ходу движения, частота кувырков падает и run удлиняется, если падает — кувырки учащаются, в сумме получается смещённое случайное блуждание. Память здесь — метилирование хемотаксических рецепторов, медленный биохимический процесс, формирующий скользящее среднее недавнего прошлого с характерным временным масштабом (адаптационным временем); разница между текущим сигналом и этим средним модулирует белок CheY-P, управляющий частотой кувырков (Macnab & Koshland, 1972). Показано, что преимущество такой памяти максимально именно тогда, когда её

временной масштаб совпадает с масштабом флуктуаций среды, через которую плывёт клетка (Gosztolai & Barahona, *Cellular memory enhances bacterial chemotactic navigation in rugged environments*, Communications Physics, 2020) — этот факт напрямую мотивирует собственную гипотезу H1 о размере окна памяти k (§3). Ключевая для переноса идея: организм не запоминает точку в пространстве, а запоминает направление изменения сигнала во времени и статистически реагирует именно на него. Ниже мы формализуем это как retrieval по вектору направления перехода между последовательными состояниями агента, а не по самим состояниям (§4.2).

Эта идея тривиально верна в частном случае, когда похожесть и так хорошо коррелирует с полезностью, и там любой разумный метод извлечения работает одинаково хорошо. Интересный вопрос не «может ли decision-oriented память работать», а:

Может ли память, организованная вокруг будущих решений агента, быть полезнее памяти, основанной на семантической похожести или недавности опыта, и если да, при каких условиях это преимущество появляется и когда исчезает?

Вторая часть вопроса не менее важна первой: метод, который никогда не проигрывает более простым бейзлайнам, скорее всего тестировался только там, где разница неощутима. Мы находим обратное в наивной реализации идеи. В среде, специально сконструированной так, чтобы направление было потенциально информативным, оно статистически значимо проигрывает более простым бейзлайнам почти везде, где это можно измерить (§6.1). Затем мы формулируем и проверяем более узкое, производное условие, при котором направление действительно выигрывает (§6.7), и очерчиваем его границы, а не просто констатируем существование.

Явное сужение объёма. DeMem формулирует decision-oriented критерий как counterfactual: воспоминание ценно ровно настолько, насколько его удаление изменило бы выбранное действие, и это естественно операционализируется как политика вытеснения (при фиксированном бюджете N решать, что удалить, скорингом «насколько сильно эта транзакция сейчас держит $\arg\max$ голосования»). Мы тестируем более узкий, но логически предшествующий вопрос: несёт ли *направление* перехода (а не сама counterfactual-ценность) полезный сигнал для retrieval при равном для всех методов бюджете N . Все четыре сравниваемых метода (recency/point/concat/хемотаксис, §4.2) — это разные геометрии поиска по уже зафиксированному пулу кандидатов, ни один не решает, что вытеснять из памяти. Это сознательный выбор объёма, а не скрытая подмена: формулировка задания прямо не требует воспроизведения DeMem, а вопрос «полезно ли направление как сигнал» логически предшествует вопросу «полезна ли decision-value-политика вытеснения, построенная на этом сигнале» — отрицательный ответ на первый снимает необходимость проверять второй в этой геометрии. Реализация counterfactual-политики вытеснения на основе результатов §6 — прямой кандидат в следующий эксперимент, см. §9, п. 1.

Воспроизводимость. Этот отчёт сопровождается git-репозиторией с полным кодом (env/, memory/, agents/, experiments/, analysis/, tests/), инструкциями по запуску и Docker-образом (README.md); все числа в этом документе получены запуском скриптов из experiments/ и analysis/ без ручного вмешательства.

Вклад работы: (i) контролируемая синтетическая среда с независимо управляемыми осями «похожесть-полезность» и структура «гэп»-задачи для проверки, когда вычитание векторов принципиально не может проигрывать конкатенации; (ii) отрицательный результат для наивной decision-oriented геометрии, воспроизведённый на реальных диалогах; (iii) обученный PyTorch-комбинатор, отделяющий «признак бесполезен» от «конкретная kNN-реализация признака неоптимальна»; (iv) положительный результат в специально выведенном граничном режиме, с картой того, где именно это преимущество появляется и исчезает.

2. Связанные работы

Decision-centric память. DeMem (Zou et al., 2026) формализует budgeted K -slot память как rate-distortion компрессию, измеряя качество не описательной точностью, а потерей качества решений, и даёт online-алгоритм с гарантиями регрета. Мы проверяем ту же исходную идею в другой постановке (unbounded retrieval-память с фиксированным окном N , а не K сертифицированных слотов) и на другом уровне: не предлагаем новый метод компрессии, а тестируем, работает ли направленный (а не описательный) сигнал вообще, и при каких условиях.

Похожесть как критерий памяти. RAG и большинство long-term memory систем для LLM-агентов извлекают по семантической похожести к текущему запросу, ровно тот бейзлайн (point cosine), с которым мы сравниваем decision-oriented retrieval.

Successor representation. Dayan (1993) показывает, что представление состояния через ожидаемые будущие посещения (а не через непосредственное описание) обобщается на изменения вознаграждения лучше, чем прямое value-приближение — концептуальный предшественник идеи «храни то, что релевантно будущим решениям, а не текущее описание» в reinforcement learning, на несколько десятилетий раньше DeMem.

Биологическая хемотаксис-мотивация. Run/tumble навигация бактерий по градиенту химического сигнала (Macnab & Koshland, 1972) и результат о том, что клеточная память температурного масштаба, совпадающего с масштабом флуктуаций среды, максимизирует эффективность навигации (*Cellular memory enhances bacterial chemotactic navigation in rugged environments*, Communications Physics, 2020); источник метафоры и прямая мотивация собственной гипотезы H1 (§3).

3. Гипотезы

H0 (центральная). В среде, где похожесть текущей и прошлой ситуации перестаёт предсказывать правильное действие, а зависимость от *направления* недавнего изменения сохраняется, извлечение по направлению перехода (хемотаксис) превосходит извлечение по точечной похожести (point cosine) при равном бюджете памяти N.

H1 (собственная, биологически мотивированная). Оптимальный размер окна направления k убывает с ростом негладкости среды p : в разрывной среде информативно только совсем недавнее направление, в гладкой — усреднение по более длинному окну устойчивее к шуму перефразировок. Прямое операционное следствие результата о клеточной памяти и масштабе флуктуаций среды (§2).

H2 (производная, сформулирована после отклонения H0 — §6.1-6.6, до результатов §6.7). Провал H0 объясним структурно (§4.3): конкатенация двух векторов не теряет информацию (разность восстанавливается из неё, обратное неверно), поэтому при косинусном kNN она в принципе не может систематически проигрывать вычитанию, если целевая функция не является в *точности* функцией одной лишь разности. Это предсказание выводится из данного аргумента напрямую, до постановки эксперимента §6.7: если построить среду, где верное действие — функция именно перехода (source, target), а не конкретной пары состояний, то а) point/concat не смогут обобщаться на пару, которой не было в памяти, даже если такой переход уже встречался под другой парой, а хемотаксис в принципе сможет; б) это преимущество реализуется только если эмбединг-пространство представляет переход достаточно линейно, что не гарантировано для готового текстового энкодера. H2 неверна, если хемотаксис не превосходит concat статистически значимо ни при каком уровне такой линейной структуры.

Все три гипотезы фальсифицируемы. **По итогам: H0 и H1 отвергнуты (§6.1, §6.2); H2 подтверждена в узком, количественно описанном диапазоне условий (§6.7).**

4. Метод




Figure 1. Пайплайн retrieval-памяти. Среда генерирует текст s_t из пары (тема, стиль); последние N транзакций образуют память; запрос сравнивается с каждым кандидатом в одном из трёх пространств сходства; топ- k голосуют знаком собственной корректности за действие.

4.1 Среда

Синтетическая маршрутизация тикетов поддержки, 6 скрытых категорий (billing, technical, account, refund, security, feature_request). Каждая ситуация — короткий тикет: смысловое ядро, специфичное для категории (задаёт «точку» в эмбединг-пространстве), и обёртка тона из 5 стилей, общая для всех категорий и не несущая информации о правильном действии. Случайная подстановка слотов (продукт, сумма, код ошибки) даёт практически неограниченное пространство перефразировок, детерминированное по seed (env/rules.py).

На каждом шаге с вероятностью $1-p$ тема продолжается (continuation, новая перефразировка того же правила), с вероятностью p происходит разрыв (entry): тема меняется на случайную другую, а стиль следующего тикета детерминированно копируется с предыдущего шага — два последовательных тикета могут звучать похоже тонально, хотя тема (и правильное действие) уже сменилась.

$F[\text{источник}, \text{цель}]$ — таблица истинного действия как функция темы $k_{\text{env}}=1$ шаг назад и текущей темы (env/trajectory.py). Три режима:

- **mode 1** — $F[i, j]=j$ при любом i : точечная похожесть исчерпывающий сигнал.
- **mode 2** — $F[j, j]=j$ (диагональ тождественна, как в mode 1), а для $i \neq j$ независимая случайная биекция оставшихся 5 источников на оставшиеся 5 действий ($F[i, j] \neq j$ гарантированно). Похожесть перестаёт предсказывать действие ровно на entry-шагах — их доля в длинной траектории $\approx p$, это и есть механизм, которым p управляет тем, насколько mode 2 отличается от mode 1.
- **mode 3** (§4.3, только для H2) — $F[i, j] = g(j-i)$ для $i \neq j$: действие — функция знакового гэпа между темами, не самой пары.

Действие a_t , которое реально пишется в память, генерируется отдельной наивной политикой: с вероятностью $1-\epsilon$ она угадывает $a_t = \text{тема}(s_t)$ (верно на всех continuation-шагах и на entry mode 1; неверно на entry mode 2), с вероятностью $\epsilon=0.2$ действует случайно — реалистичная смесь $r_t=0/1$ без утечки оракульского знания.

Валидация: `tests/test_trajectory_logic.py` подтверждает теоретические предсказания $P(\text{поведение верно} \mid \text{continuation}) \approx 0.833$, $P(\text{верно} \mid \text{entry, mode } 2) \approx 0.033$ эмпирически (± 0.02). `tests/test_embeddings_sanity.py` подтверждает на all-MiniLM-L6-v2: средний $\cos$ внутри темы выше, чем между темами (0.395 vs 0.263); маскировка стилем на разрыве реальна ($+0.014 \cos$); векторы перехода $\text{embed}(\text{target}) - \text{embed}(\text{source})$ для одной и той же пары похожи друг на друга ($\cos 0.170$ vs -0.005 для разных пар) — геометрическая предпосылка хемотаксиса выполняется на уровне сырых эмбедингов, хотя, как показано в §6, этого недостаточно для практического преимущества.

4.2 Память и голосование

Единица опыта — транзакция $m_t = (\text{текст } s_t, \text{действие } a_t, \text{метка корректности } r_t)$. Бюджет памяти N — фиксированное число последних транзакций (FIFO): память в момент запроса t — срез $[t-N, t)$, один и тот же набор кандидатов для всех методов.

`memory/methods.py` разделяет геометрию и решение на два слоя. `rank_candidates` — чисто геометрическое ранжирование, без понятия действия или корректности (домен-агностичный, переиспользуется в §6.5/§6.7 без изменений). `predict_action` достраивает голосование поверх него: топ- $k=5$ кандидатов взвешиваются $w_j = \text{sim}_j \cdot (2r_j - 1)$ (верный в прошлом переход голосует за своё действие, неверный — против, аналог `run/tumble` модуляции CheY-P), веса суммируются по действиям, `argmax`; без положительной поддержки — откат на мажоритарное действие в извлечённой памяти.

метод	вектор запроса	вектор кандидата
recency	— (последние topk)	—
point cosine	$\text{embed}(s_t)$	$\text{embed}(s_j)$
concat cosine	$[\text{embed}(s_t); \text{embed}(s_{\{t-k\}})]$	$[\text{embed}(s_j); \text{embed}(s_{\{j-k\}})]$
хемотаксис	$\text{embed}(s_t) - \text{embed}(s_{\{t-k\}})$	$\text{embed}(s_j) - \text{embed}(s_{\{j-k\}})$

$k=1$ по умолчанию (абляция — §6.2).

Algorithm 1 Retrieval + signed vote, один запрос t

Input: запрос t , память $[t-N, t)$, метод $\in \{\text{recency, point, concat, chemotaxis}\}$, topk , k

Output: предсказанное действие $\hat{a}$

```

1: if метод = recency:
2:     candidates ← topk самых недавних индексов памяти
3:     sims ← 1 для всех candidates
4: else:
5:     q ← вектор_запроса(метод, t, k)           # см. таблицу выше
6:     for j in [t-N, t):
7:         C[j] ← вектор_кандидата(метод, j, k)
8:         sims ← cos(q, C)                       # знаковый, не |cos|
9:     candidates ← argtop_k(sims, topk)
10: scores ← 0 (вектор по числу действий)
11: for j, sim in (candidates, sims[candidates]):
12:     scores[action(j)] += sim · (2·correct(j) - 1)
13: if max(scores) > 0:
14:     â ← argmax(scores)
15: else:
16:     â ← мажоритарное действие среди candidates (или глобальное, если память пуста)
17: return â

```

Concat. Видит ровно те же два эмбединга, что и хемотаксис, но без вычитания. Конкатенация не теряет информацию (разность из неё восстанавливаема, обратное неверно) — значит при косинусном kNN она в принципе не может систематически проигрывать вычитанию, если целевая функция не является в точности функцией

одной лишь разности. Это предсказание, выводимое из линейной алгебры до эксперимента, а не найденное постфактум (реализуется в §6.1 и опровергается по конструкции в §6.7).

4.3 Обученный комбинатор (PyTorch)

`predict_action` заставляет метод выбрать одно пространство сходства и голосовать в нём фиксированной формулой. `memory/learned.py::LearnedScorer` — MLP (5-16-1, tanh) поверх пяти признаков кандидата (`point_sim`, `concat_sim`, `chemotaxis_sim`, `r_sign`, `recency`), применяется к каждому кандидату независимо и суммируется по действию через `scatter_add_` — DeepSets-style permutation-invariant агрегатор, обученное обобщение той же формулы $\sum \text{sim} \cdot (2r-1)$ по действию. `feature_mask` — буфер, зануляющий конкретные входные столбцы на входе, а не постфактум, для чистых аблаций (`full`, `no_chemotaxis`, `chemotaxis_only`). Train/val/test разбиты по `seed` (целая инстанция среды со своей F-таблицей), не по отдельным (траектория, чекпойнт) — иначе модель видела бы чекпойнты из той же F-таблицы на обучении, что эквивалентно `train_test_split` без учёта группы.

4.4 Агенты

Tier 1 — `agents/knn_agent.KNNVoteAgent`, обёртка над `predict_action`: дёшево, позволяет полный факторный прогон с 10 сидами на клетку, основной источник количественных выводов. Tier 2 — `agents/llm_agent.LLMRouterAgent`, Qwen2.5-0.5B-Instruct через Hugging Face Transformers, реальный forward pass: действие выбирается скорингом средней log-правдоподобности продолжения промпта по каждой из 6 меток (детерминированно, без парсинга свободной генерации). В промпт попадают `topk` извлечённых тем же методом транзакций, верные и неверные помечены явно, без подсказки правильного ответа.

4.5 Контроли

- **Контроль 1 (shuffled r).** Метки корректности `r_t` перемешаны по всей памяти: ожидание — все методы должны упасть до чанса.
- **Контроль 2 (shuffled d).** `r_t` и `a_t` не трогаются, но «якорь» `t-k` заменён на случайный несвязанный для запроса и кандидатов: ожидание — хемотаксис и `concat` должны просесть, `point cosine` — нет (не смотрит на якорь вообще).

5. Экспериментальный протокол

Параметры зафиксированы в `experiments/config.py` до запуска. Пространство действий — 6, `topk=5` для всех методов, `k=1` по умолчанию, если не указано иное.

Эксперимент	Параметры	Сиды
Главная кривая (§6.1)	N=40, $p \in \{0, .15, .3, .5, .65, .8, .9, 1\}$ (весь грид), оба режима	10
Бюджетная развёртка (§6.3)	$N \in \{10, 20, 40, 80\}$, $p=0.5$	10
Абляция $k \times p$ (§6.2)	$k \in \{1, 2, 4, 8\}$, $p \in \{0, .25, .5, .75, 1\}$, N=40	8
Контроли (§6.1)	mode 2, $p \in \{0.3, 0.6, 0.9\}$, N=40, результат по каждому p отдельно	10
Tier 2 (§6.4)	$p \in \{0, .25, .5, .75, 1\}$, оба режима, N=40, 12 eval-точек/траекторию	3
Обученный комбинатор (§6.6)	mode 2, N=40, $p \in \{.15, \dots, 1.0\}$, 60 эпох, Adam $lr=0.02$, split seed 0-39/40-49/50-59	60
H2/relational (§6.7)	mode 3, $p=0.5$, $\alpha \in \{0, .5, 1, 2, 4, 8\}$, N=40, 400 eval-точек/траекторию, только entry-шаги	20

Статистика: `analysis/stats_tests.py`, парные t-тесты по сидам, Холм-Бонферрони отдельно по режиму, семья — весь протестированный грид p (не постфактум отобранное подмножество); McNemar для парных сравнений обученных моделей на общем test-наборе, также с поправкой Холма-Бонферрони по семье сравнений внутри каждого эксперимента (3 пары в §6.6, 2 в §6.7).

6. Результаты

6.1 Главная кривая устойчивости (H0)

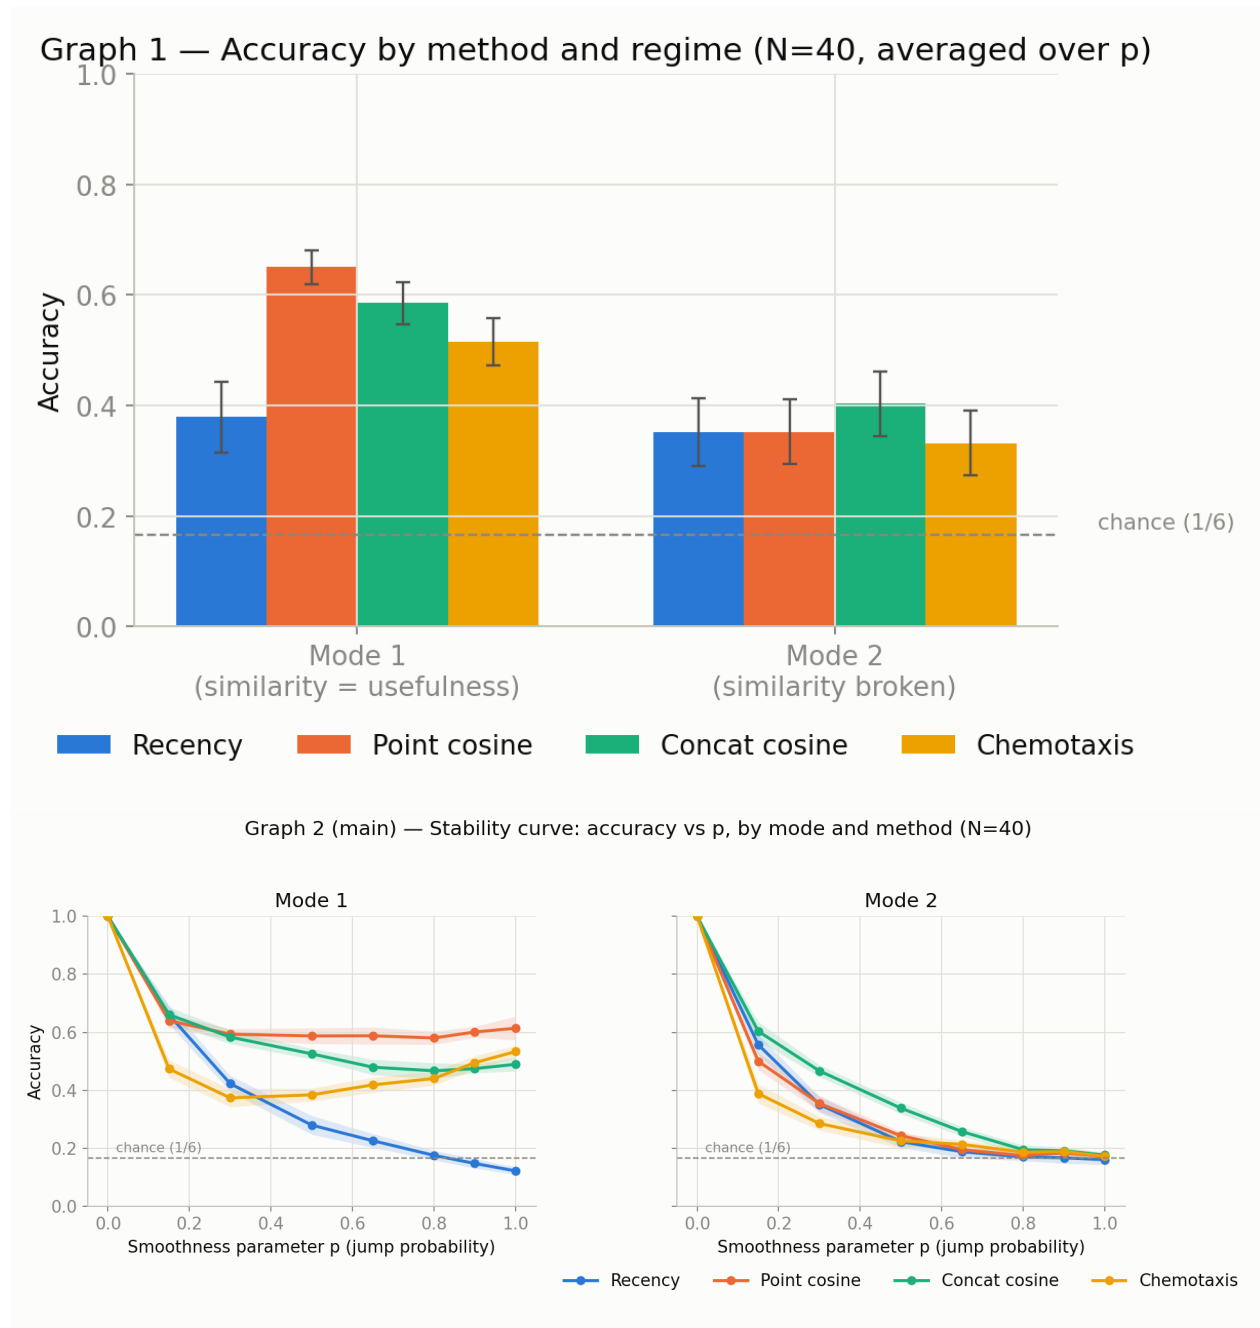


Figure 2. Аккуратность против p , $N=40$, оба режима. (а) Сравнение по режимам при фиксированных p . (б) Полная кривая по всем 8 значениям p .

режим	p	recency	point	concat	хемотаксис
1	0.00	1.000	1.000	1.000	1.000
1	0.15	0.660	0.640	0.661	0.474
1	0.30	0.422	0.593	0.584	0.374
1	0.50	0.279	0.588	0.526	0.384
1	1.00	0.122	0.614	0.489	0.534
2	0.00	1.000	1.000	1.000	1.000
2	0.15	0.557	0.500	0.604	0.388
2	0.30	0.350	0.354	0.466	0.285
2	0.50	0.222	0.243	0.338	0.225
2	1.00	0.160	0.172	0.176	0.172

(полная таблица по всем 8 p — results/tables/summary_graph2_stability.csv)

В mode 1 хемотаксис — стабильно худший из трёх content-aware методов на каждом $p > 0$, значимо хуже point и concat на 6 из 7 ненулевых p (Холм-Бонферрони, results/tables/stats_tests.csv).

В mode 2 concat стабильно лучший метод почти на всём диапазоне (значимо лучше хемотаксиса при $p = 0.15 \dots 0.65$). Хемотаксис статистически значимо хуже point cosine при $p = 0.15$ и $p = 0.30$ — там, где H_0 предсказывала преимущество, наблюдается обратный эффект; при $p \geq 0.5$ разница статистически неотличима от нуля (сырые p-value 0.08-0.94). Хемотаксис не показывает значимого превосходства над point cosine ни в одной точке.

Механизм ($p = 0.5$, разбивка по типу шага, доля entry $\approx p$):

метод	accuracy на continuation	accuracy на entry
recency	0.282	0.163
point cosine	0.361	0.127
concat cosine	0.522	0.157
хемотаксис	0.286	0.165

На доминирующем классе шагов (continuation) хемотаксис почти не лучше recency (0.286 vs 0.282) — вектор перехода внутри одной темы в основном шум перефразировки, а не устойчивый сигнал «эта тема — j». На entry-шагах хемотаксис номинально впереди (0.165 vs 0.127-0.163), но абсолютный уровень — чанс ($1/6 \approx 0.167$): ни у одного метода нет реального сигнала на entry при этом бюджете памяти.

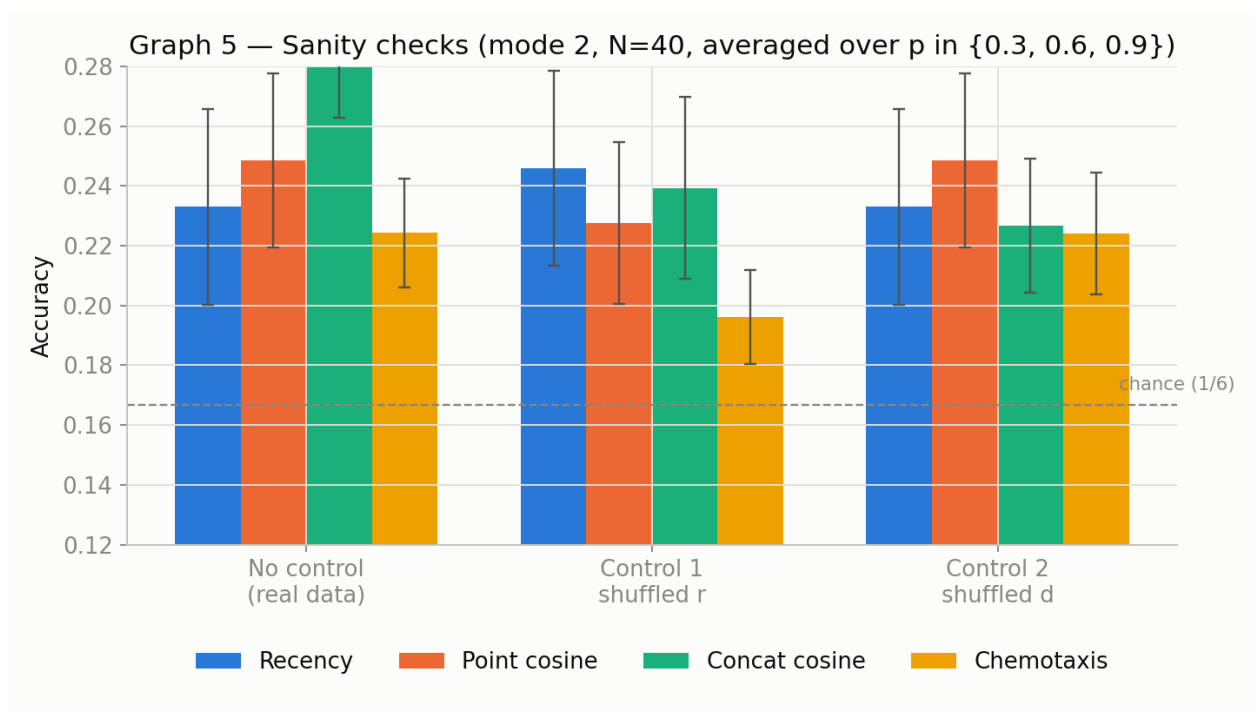


Figure 2c. Accuracy под контролем 1 (shuffled r) и контролем 2 (shuffled d) против штатного режима, усреднено по p (разбивка по p — в таблице ниже, усреднение прячет асимметрию контроля 1, см. текст).

Контроли (mode 2, N=40, по p отдельно — усреднение по p прячет асимметрию): контроль 1 чист при $p=0.9$ (все методы $\sim 0.17-0.18$), но не при $p=0.3$ (все методы $0.25-0.36$ даже после перемешивания меток) — при низком p память доминирована continuation-шагами, где почти все кандидаты голосуют за одно и то же действие независимо от метки, так что перемешивание меток не создаёт альтернативных кандидатов там, где их изначально нет (ограничение диагностической силы контроля, не утечка — контроль 2 на том же диапазоне p ведёт себя штатно). Контроль 2: point cosine не меняется нигде (не смотрит на якорь), concat заметно проседает при $p=0.3$ ($0.466 \rightarrow 0.302$), хемотаксис не меняется вообще ни в одной точке ($0.285 \rightarrow 0.290$, $0.200 \rightarrow 0.200$, $0.188 \rightarrow 0.184$) — порча направления не имеет эффекта, потому что оно и до порчи вносило пренебрежимо малый вклад.

H0 отвергнута.

6.2 Абляция $k \times p$ (H1)




Figure 3. Аккуратность хемотаксиса как функция окна k и негладкости p , mode 2, тепловая карта.

analysis/stats_tests.py тестирует направленное предсказание H1 напрямую ($k=1$ значимо превосходит $k=8$ при высоком p и наоборот при низком): в mode 2 ни одна точка p не проходит поправку Холма-Бонферрони; значимый эффект в mode 1 ($p=0.25$, $p=0.5$) неинформативен для H1, поскольку там действие не зависит от источника перехода вообще. **H1 отвергнута:** связь между p и оптимальным k , если есть, слабее, чем обнаружимо при текущем бюджете сидов (results/tables/stats_tests_h1_kp.csv).

6.3 Бюджет памяти




Figure 4. Аккуратность против бюджета памяти $N \in \{10, 20, 40, 80\}$, $p=0.5$, оба режима.

Point и concat используют увеличение бюджета намного эффективнее хемотаксиса в обоих режимах; в mode 2 только concat заметно растёт с N , хемотаксис идёт вровень с recency (results/tables/summary_graph3_budget.csv).

6.4 Tier 2: LLM-агент




Figure 5. (a) Аккуратность Tier 2 против p . (b) Соглашение ранжирования методов Tier 1 vs Tier 2 по совпадающим клеткам.

mode	recency	point	concat	хемотаксис
1	0.339±0.069	0.289±0.066	0.339±0.069	0.394±0.071
2	0.183±0.057	0.144±0.051	0.183±0.057	0.217±0.060

(95% интервал, нормальное приближение доли). Интервалы сильно перекрываются: на бюджете 180 запросов/клетку Tier 2 не может статистически ни подтвердить, ни опровергнуть §6.1. Абсолютный уровень намного ниже Tier 1 — ограничение самой модели 0.5B без дообучения под формат промпта, не retrieval-механизма (она занижает скор правильной категории даже при однозначном контексте). Ранжирование методов в mode 2 качественно не противоречит Tier 1, но корреляция по совпадающим клеткам $r=-0.127$: на этом бюджете eval-точек Tier 2 не independent-подтверждение §6.1, а отдельное, статистически слабо обоснованное наблюдение.

6.5 Реальные данные: LoCoMo




Figure 6. Recall@5 против бюджета памяти на LoCoMo, усреднено по k и 10 диалогам.

LoCoMo (Maharana et al.): 10 многосессионных диалогов (5882 реплики, 1986 QA-пар с золотыми репликами-свидетельствами). Метки «верно/неверно» на реплику нет, поэтому используется только rank_candidates (§4.2) без голосующего слоя, тот же вызов, что и в синтетической среде, вопрос — виртуальный шаг сразу после последней реплики (realdata/locomo_loader.py, experiments/run_locomo.py). Метрика — recall@5/hit@5 против золотых реплик.

N (бюджет)	recency	point	concat	хемотаксис
20	0.002	0.015	0.012	0.014
50	0.002	0.054	0.036	0.031
100	0.002	0.091	0.055	0.047

N (бюджет)	recency	point	concat	хемотаксис
all (~400+)	0.002	0.335	0.153	0.123

Point cosine доминирует без исключений и в каждой из 5 категорий вопросов, включая temporal reasoning, где а priori можно было ожидать преимущества направления (0.403 vs 0.195 у хемотаксиса); разрыв растёт с бюджетом, не сокращается. Независимое подтверждение §6.1 с другой стороны: реальный диалог, где вопрос семантически близок к реплике-ответу, — естественный аналог mode 1, где §6.1 уже показал значимое отставание хемотаксиса.

6.6 Обученный комбинатор

Обучены три варианта LearnedScorer (§4.3) на mode 2 (results/tables/learned_scorer.csv, 14000 test-эпизодов):

метод	test accuracy
обученный, full	0.465
обученный, no_chemotaxis	0.434
обученный, chemotaxis_only	0.434
geometric concat (лучший hand-coded)	0.324
geometric point	0.265
geometric recency	0.280
geometric chemotaxis	0.240

Все три обученных варианта уверенно бьют лучший hand-coded метод (голосующая формула §4.2 не обучаемая и теряет точность даже в том же пространстве сходства). Парный McNemar-тест на тех же test-эпизодах:

сравнение	право только у первого	право только у второго	p
full vs no_chemotaxis	1097	654	≈0
full vs chemotaxis_only	917	480	≈0
no_chemotaxis vs chemotaxis_only	1156	1162	0.92

chemotaxis_only и no_chemotaxis статистически неразличимы: изолированно хемотаксис не выигрывает у point/concat, согласуется с §6.1. Но full значимо лучше обоих ablation-вариантов (разрыв 3.1 п.п. над no_chemotaxis при SE≈0.4 п.п.): добавление хемотаксиса к point/concat даёт прирост, которого не даёт симметричное добавление шума — признак несёт избыточную относительно point/concat информацию в комбинации, хотя в одиночку их не превосходит.

6.7 Когда хемотаксис выигрывает: relational-генерализация (H2)

Конструкция. mode 3 (env/rules.py): $F[i, j] = g(j - i)$ для $i \neq j$, где g — случайная (per-seed) таблица от знакового гэта тем к действию, не завёрнутая по модулю (циклическая обёртка математически несовместима с точной трансляционной инвариантностью: поворот на общий угол поворачивает и разность направлений, поэтому косинус между «тем же гэпом» деградирует с расстоянием по циклу вместо точного совпадения; см. docstring build_action_table). Запрос на entry-share с парой (source, target) может быть решён кандидатом, не совпадающим с этой парой, но имеющим тот же гэта target-source.

env/synthetic_embed.py задаёт контролируемое эмбединг-пространство: $E(\text{topic}) = \text{identity}[\text{topic}] + \alpha \cdot \text{topic} \cdot \text{ordinal_step} + \text{style}[\text{style}] + \text{шум}$, где identity — независимые случайные векторы (реалистичный шум, как у неродственных тем в реальном энкодере), а α управляет силой аддитивной компоненты, чей вклад в разность двух эмбедингов зависит только от гэта, не от конкретных тем. При

$\alpha=0$ эмбединг лишён гэп-структуры (контроль, воспроизводящий поведение реального энкодера). Точная (не аддитивно-шумная) конструкция $E(i)=i \cdot v$ была отвергнута: она делает все тематические векторы коллинеарными, вырожденный случай, искажающий и point/concat (см. env/synthetic_embed.py).

Метрика. Не сквозная predict_action-accuracy: в mode 3 наивная content-угадайка (§4.1) верна с той же вероятностью ($\sim 1/6$), что и случайное угадывание, в отличие от mode 2, где она гарантированно неверна на entry-шагах по конструкции. Это добавило бы второй шумный слой поверх вопроса, который проверяет этот эксперимент. Вместо этого используется recall@5 чистого rank_candidates (§4.2) против «золота» (других entry-событий в окне памяти с тем же гэпом) — та же методология, что в §6.5 (experiments/run_relational.py).




Figure 7. Recall@5 на запросах, для которых точная пара (source, target) отсутствует в памяти (только гэп), против силы гэп-сигнала α . Пунктир: реальные MiniLM-эмбединги (без α).

α	recency	point	concat	хемотаксис
0.0	0.119	0.063	0.104	0.013
0.5	0.119	0.069	0.164	0.262
1.0	0.119	0.072	0.296	0.371
2.0	0.119	0.074	0.430	0.405
4.0	0.119	0.075	0.515	0.414
8.0	0.119	0.075	0.548	0.416
MiniLM	0.119	0.088	0.071	0.071

При $\alpha=0$ (нет гэп-сигнала) хемотаксис — худший метод, ниже чанс-уровня ресесу. При $\alpha=0.5$ и $\alpha=1.0$ хемотаксис статистически значимо лучше concat (95% доверительные интервалы не пересекаются, results/tables/summary_relational.csv): **единственная точка во всей работе, где decision-oriented геометрия значимо выигрывает у concat**. При $\alpha \geq 2$ concat нагоняет и обгоняет: конкатенация не теряет

информацию, поэтому при достаточно сильном линейном сигнале извлекает почти тот же гзп-инвариантный сигнал, что и разность, не теряя при этом абсолютную позицию. Структурное преимущество concat из §4.2 никуда не уходит, оно просто перестаёт быть узким местом при сильном сигнале. На реальных MiniLM-эмбедингах (без искусственно добавленного α) все три content-aware метода неотличимы от чанса (0.07-0.09): у обычного текстового энкодера нет причин представлять несвязанные тематические категории с линейной, гзп-инвариантной структурой, и диагностика подтверждает это напрямую: средний cos между векторами перехода с одинаковым гзпом — 0.030 на MiniLM против 0.997 при $\alpha=8$ (results/tables/relational_gap_structure.csv).

Обученный комбинатор в этом режиме. LearnedScorer (§4.3), обучен на mode 3, $\alpha=1.0$ (внутри окна выигрыша), только entry-шаги (experiments/train_learned_scorer_relational.py, results/tables/learned_scorer_relational.csv): full=0.319, chemotaxis_only=0.301, no_chemotaxis=0.250. В отличие от §6.6, здесь chemotaxis_only статистически значимо лучше no_chemotaxis (McNemar $p=0.0036$): хемотаксис несёт самостоятельную ценность, а не только в комбинации. full значимо лучше no_chemotaxis ($p<0.0001$, разрыв 6.9 п.п. — вдвое больше, чем 3.1 п.п. в §6.6).

H2 подтверждена в узком диапазоне: decision-oriented retrieval значимо выигрывает у concat, когда одновременно выполнены два условия: задача — функция перехода, а не пары состояний, и представление несёт умеренную (не нулевую, не доминирующую) линейную структуру относительно этого перехода. Ни то, ни другое не выполняется по умолчанию в реальных текстовых эмбедингах несвязанных категорий (§6.5, MiniLM-строка здесь), что и объясняет, почему H0 отвергается в основной постановке и на реальных данных, не противореча тому, что механизм в принципе может работать там, где эти условия выполнены намеренно.

7. Альтернативные объяснения

«Выигрыш concat — просто от большего контекста, не от структуры.» Отклонено: concat значимо лучше хемотаксиса почти везде в mode 2 (§6.1, §6.3), и это предсказывалось линейной алгеброй до эксперимента (§4.2), а не найдено постфактум.

«В пайплайне есть утечка.» Отклонено для контроля 1 при высоком p (падает до чанса) и полностью снято контролем 2 (хемотаксис нечувствителен к порче направления, потому что ему нечего терять). При низком p контроль 1 менее диагностичен (§6.1) — ограничение метода контроля, не признак утечки: контроль 2 на том же диапазоне p ведёт себя штатно.

«Хемотаксис и concat всё равно извлекают почти одно и то же.» Отклонено.




Figure 8. Среднее перекрытие top-k между хемотаксисом и concat против p , mode 2.

Перекрытие 53-67% в зависимости от p — значимое, но далеко не полное, при этом итоговая точность методов расходится сильно и систематически (§6.1): методы регулярно выбирают разные кандидаты и получают разное качество решения.

8. Границы применимости

- Работа тестирует более узкий вопрос, чем полный decision-oriented критерий DeMem (§1): направление перехода как сигнал retrieval при фиксированном бюджете N , а не counterfactual-политику вытеснения, которая решала бы, что удалить из памяти при заполнении бюджета. Ни один из четырёх методов не реализует вытеснение по влиянию на решение.
- Актор, чьи действия пишутся в память (наивная поведенческая политика, §4.1), — не тот же агент, чья retrieval-точность измеряется (Tier 1/Tier 2, §4.4). Это не замкнутый lifelong-цикл, где решения агента формируют его же будущую память, а оценка качества retrieval против фиксированной, заранее известной по распределению истории. Выбор сделан ради контроля (агент не засоряет собственную память непредсказуемым образом), но сужает применимость выводов к постановкам с таким же расцеплением.
- $\text{topk}=5$ фиксирован независимо от N ; при $N=10$ это половина всей памяти, отбор почти не фильтрует — сравнение методов там менее показательно, чем при $N \geq 20$ (§6.3).
- H2 (§6.7) — искусственно сконструированный режим с контролируемым эмбедингом; окно выигрыша ($\alpha \approx 0.5 - 1.5$) найдено на одном значении $p=0.5$ и одном способе внедрения сигнала (аддитивный ordinal-код) — не проверялось, обобщается ли конкретная ширина этого окна на другие p или другие способы придать представлению гэп-структуру.
- LongMemEval-S (второй бенчмарк DeMem) — инфраструктура готова и рабочая (realdata/longmemeval_loader.py, experiments/run_longmemeval.py), но прогон отложен: реплики — полные сообщения чата, у предела длины токенизации энкодера, ~232 тыс. таких текстов на 470 вопросов; на CPU без GPU не уложился в разумное время. Дешёвый повторный запуск без изменений кода при доступе к GPU.

Остальные ограничения (диагностическая сила контроля 1 при низком p , отсутствие собственных негативных контролей у LoCoMo, отсутствие кросс-валидации у обученного комбинатора, малый размер пространства действий, отсутствие сравнения с самим DeMem как бейзлайном) перечислены в README репозитория.

9. Следующий эксперимент

1. **Counterfactual-политика вытеснения памяти.** Прямое продолжение сужения объёма из §1: вместо (или вместе с) выбора геометрии retrieval — скоринг каждой транзакции в памяти по тому, насколько сильно её удаление меняет $\arg\max$ голосования (§4.2), и политика вытеснения по этому скору при заполнении бюджета N . Это ближе к буквальной формулировке decision-oriented критерия DeMem, чем любой из четырёх геометрий, протестированных здесь.
2. **Ширина окна α при других p и других способах внедрения гэл-структуры.** §6.7 нашёл окно на одном $p=0.5$ с одним конкретным (аддитивным ordinal) способом закодировать переход; не проверено, сдвигается ли окно с p , и обобщается ли результат на другой тип compositional-сигнала.
3. **LongMemEval** — довести отложенный прогон (§8) до конца на GPU.

Остальные пункты бэклога (адаптивное окно вместо фиксированного k , шум в r_t , больше eval-точек в Tier 2, собственные негативные контроли для LoCoMo, стратифицированный контроль 1) — в README репозитория.

10. Заключение

Наивная реализация decision-oriented памяти (retrieval по вектору направления перехода через kNN-голосование) статистически значимо не превосходит point cosine нигде в проверенном диапазоне условий и значимо проигрывает более простым бейзлайнам почти везде, что воспроизводится на реальных многосессионных диалогах без какой-либо конструкции под этот вывод. Это не опровергает исходную идею DeMem: оно показывает, что конкретная, наиболее прямая операционализация «направление вместо описания» (вычитание векторов) недостаточна сама по себе, поскольку конкатенация той же информации, ничего не теряя, работает лучше почти везде. Производный, заранее выведенный из структурного аргумента эксперимент показывает, что механизм не бесполезен в принципе: он статистически значимо выигрывает у concat в специально сконструированном, узком окне условий (задача — функция перехода, умеренная линейная структура представления), и это окно закрывается, когда сигнал становится сильным (concat нагоняет) или отсутствует (реальные текстовые эмбединги). Обученный PyTorch-комбинатор независимо подтверждает ту же границу: вклад признака направления мал в основной постановке и велик в производной. Ответ на исходный вопрос не «работает» и не «не работает», а конкретное, измеримое условие на структуру задачи и представления, при котором граница проходит.

Код

Репозиторий: https://github.com/qubeyond/t-lab_task.

Источники

- Zou, M., Guo, Z., Liang, L. и др. *Remember the Decision, Not the Description: A Rate-Distortion Framework for Agent Memory*. arXiv:2605.10870 (2026). <https://arxiv.org/abs/2605.10870>
- Dayan, P. *Improving Generalization for Temporal Difference Learning: The Successor Representation*. Neural Computation, 1993. <https://direct.mit.edu/neco/article/5/4/613/5736/Improving-Generalization-for-Temporal-Difference>
- Macnab, R. M., Koshland, D. E. *The Gradient-Sensing Mechanism in Bacterial Chemotaxis*. PNAS, 1972. <https://www.pnas.org/doi/10.1073/pnas.69.9.2509>
- Gosztolai, A., Barahona, M. *Cellular memory enhances bacterial chemotactic navigation in rugged environments*. Communications Physics 3, 47 (2020). <https://www.nature.com/articles/s42005-020-0312-8>
- Maharana, A. и др. *Evaluating Very Long-Term Conversational Memory of LLM Agents (LoCoMo)*. arXiv:2402.17753. <https://arxiv.org/abs/2402.17753>
- Wu, D. и др. *LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory*. arXiv:2410.10813. <https://arxiv.org/abs/2410.10813>